




Anderson Flores Danny Lopez

GRUPO_1.pdf

-  Estad. Computacional
-  Estad. Computacional
-  Universidad Nacional del Altiplano

Detalles del documento

Identificador de la entrega

trn:oid::8254:466061303

Fecha de entrega

10 jun 2025, 3:19 p.m. GMT-5

Fecha de descarga

10 jun 2025, 3:25 p.m. GMT-5

Nombre de archivo

GRUPO_1.pdf

Tamaño de archivo

1.0 MB

9 Páginas

5949 Palabras

33.559 Caracteres

33 % detectado como IA

El porcentaje indica la cantidad de texto calificado en la entrega que probablemente se generó usando IA.

Precaución: Se requiere revisión.

Es esencial comprender los límites de la detección de IA antes de la toma de decisiones acerca del trabajo del estudiante. Lo alentamos a obtener más información acerca de las funciones de detección de IA de Turnitin antes de usar la herramienta.

Aviso legal

Nuestra evaluación de escritura con IA está diseñada para ayudar a los educadores a identificar texto que podría haberse creado con una herramienta de IA generativa. Nuestra evaluación de escritura con IA puede no ser precisa en todos los casos (existe la posibilidad de identificar erróneamente texto humano como generado con IA y probablemente generado como texto creado por humanos), por lo que no debería usarse como la única prueba para tomar acciones adversas contra un estudiante. Se necesita mayor escrutinio y criterio humano junto con la aplicación de la organización de las políticas académicas específicas de la institución para determinar si se ha incurrido en alguna mala conducta académica.

Preguntas frecuentes

¿Cómo debería interpretar los falsos positivos y el porcentaje de escritura con IA de Turnitin?

El porcentaje mostrado en el informe de escritura con IA es la cantidad del texto calificado en la entrega que el modelo de detección de escritura con IA de Turnitin determina si un texto se generó probablemente con IA desde un modelo de lenguaje grande.

Los falsos positivos (que marcan incorrectamente alertas de texto escrito por humanos como generado con IA) son una posibilidad en los modelos de IA.

Los puntajes de detección de IA inferiores a 20 %, que no aparecen en informes, tienen una mayor probabilidad de falsos positivos. Para reducir la probabilidad de malinterpretación, no se atribuye ningún puntaje o resultado y se indican con un asterisco en el informe (*%).

El porcentaje de escritura de IA no debe ser el fundamento para determinar si ha ocurrido una mala conducta. El revisor/instructor debería usar el porcentaje como un medio para iniciar una conversación formativa con sus estudiantes y/o usarlo para examinar el ejercicio enviado según las políticas de la escuela.

¿Qué significa 'texto calificado'?

Nuestro modelo solo procesa el texto calificado en el formato de escritura de formato largo. La escritura de formato largo significa que los enunciados individuales en párrafos que constituyen una parte más grande del trabajo escrito, como un ensayo, una disertación, un artículo, etc. El texto calificado que se ha determinado que se generó probablemente con IA se resaltará en color cian en la entrega.

El texto no calificado, como viñetas, bibliografías comentadas, etc., no se procesará y puede crear disparidad entre los puntos destacados del envío y el porcentaje mostrado.



Reconocimiento de Patrones Temporales en Series de Tiempo para la Predicción de Brotes de Dengue en el Perú

Anderson Brian Flores Suaña
Facultad de Ingeniería Estadística e Informática
Universidad Nacional del Altiplano
Puno, Perú
brian.fss821@gmail.com

Danny Christian Lopez Pajsi
Facultad de Ingeniería Estadística e Informática
Universidad Nacional del Altiplano
Juliaca, Perú
godau88dota@gmail.com

Resumen—Este estudio aborda la implementación de modelos de series temporales para la predicción de brotes de dengue en el Perú, comparando tres enfoques metodológicos: Prophet, ARIMA y redes neuronales LSTM. A través de técnicas avanzadas de análisis temporal, se identificaron patrones estacionales y tendencias en la incidencia del dengue durante el periodo 2020-2023, lo que permitió anticipar periodos de alto riesgo epidemiológico. La metodología integra análisis estadístico tradicional con enfoques de modelado predictivo, facilitando la toma de decisiones informadas para el control epidemiológico. Los resultados revelan patrones estacionales claros relacionados con variables climáticas, particularmente la temporada de lluvias, que favorece la proliferación del vector *Aedes aegypti*. La evaluación comparativa mediante las métricas MAE, RMSE, MAPE y R^2 demostró que el modelo ARIMA presentó el mejor rendimiento general en este conjunto de datos, combinando precisión y simplicidad operativa. Se concluye que la aplicación de modelos de series temporales constituye una herramienta eficaz para la vigilancia epidemiológica y la prevención del dengue en contextos endémicos.

Palabras clave: series temporales, dengue, predicción epidemiológica, LSTM, Prophet, ARIMA, Perú.

I. INTRODUCCIÓN

El dengue, una arbovirosis transmitida principalmente por el mosquito *Aedes aegypti*, representa un desafío significativo para la salud pública a nivel mundial. En Perú, su incidencia ha aumentado notablemente en los últimos años, particularmente en regiones tropicales y subtropicales, donde las condiciones climáticas, como altas temperaturas y humedad, favorecen la reproducción del vector. Factores como el cambio climático, el crecimiento urbano desordenado y la movilidad poblacional han contribuido a la expansión geográfica del dengue en el país [1]. Según datos del Ministerio de Salud del Perú, entre 2020 y 2023 se ha registrado un notable incremento en los casos confirmados, superando incluso cifras históricas previas [2].

En este contexto, la predicción precisa del comportamiento temporal del dengue se vuelve fundamental para planificar estrategias de control y respuesta eficiente. La modelación de series temporales ha emergido como una herramienta clave para este propósito, permitiendo analizar tendencias, estacionalidades y anomalías. En particular, la identificación

temprana de patrones temporales específicos del contexto peruano puede mejorar la asignación de recursos sanitarios y optimizar las campañas de prevención y control vectorial [3].

Diversos enfoques han sido aplicados para modelar series temporales de enfermedades infecciosas. Entre ellos, los modelos estadísticos clásicos, como el ARIMA, han demostrado ser efectivos en contextos donde las series son estacionarias o pueden transformarse en estacionarias mediante diferenciación [4]. Más recientemente, modelos como Prophet, desarrollado por Facebook, han ganado popularidad por su capacidad de descomponer series en componentes aditivos —tendencia, estacionalidad y días festivos— y por su facilidad de implementación y ajuste automático de parámetros [5]. Asimismo, los modelos basados en redes neuronales profundas, como las Long Short-Term Memory (LSTM), han mostrado un gran potencial en la captura de patrones no lineales y dependencias a largo plazo en las series temporales, superando en muchos casos a los modelos tradicionales [6].

Aunque existen estudios previos que han utilizado estos modelos para predecir enfermedades vectoriales en distintas regiones del mundo [7],[8], pocos han abordado comparativamente su rendimiento en el contexto específico del Perú, considerando sus características geográficas, climáticas y epidemiológicas particulares. Por ello, el presente estudio tiene como objetivo comparar el desempeño de tres modelos de predicción de series temporales —Prophet, ARIMA y LSTM— en la estimación de casos de dengue en Perú durante el periodo 2020-2023.

II. DATOS

A. Datos

Para este estudio, se utilizaron datos históricos de casos de dengue reportados en Perú entre 2000 y 2023, pero para este análisis nosotros usamos los datos desde el año 2020 al 2023, obtenidos desde la plataforma de datos abiertos del Ministerio de Salud del Perú [009].

A continuación, se presentan diferentes visualizaciones de los datos utilizados:

III. MÉTODOLOGÍAS

Lo primero que se hizo fue, cargar los datos (CSV) de vigilancia del dengue del 2000 al 2023. Luego, se aplicó un filtro para conservar solo las filas donde el año ('ano') esté entre 2020 y 2022. Esto se hizo usando una condición lógica sobre la columna del año. El resultado es un nuevo archivo CSV que contiene únicamente los registros correspondientes a ese rango de años, sin alterar ni transformar los demás datos. Para luego ser usado en los siguientes modelos.

El análisis de series de tiempo para la predicción epidemiológica requiere un enfoque metodológico robusto que considere la naturaleza compleja y no estacionaria de los datos de salud pública [4]. En este estudio, se implementó una estrategia de modelado comparativo que integra técnicas estadísticas tradicionales con métodos de aprendizaje automático avanzados.

Se aplicaron técnicas de análisis de series de tiempo, incluyendo modelos ARIMA (AutoRegressive Integrated Moving Average) y SARIMA (Seasonal ARIMA), para identificar patrones estacionales y tendencias en la incidencia de casos de dengue [5]. Además, se utilizaron análisis de correlación cruzada para evaluar la relación entre las variables climáticas y la incidencia de la enfermedad [7].

La metodología se estructuró en cuatro fases principales: (1) preprocesamiento y exploración de datos, (2) evaluación de estacionariedad y transformaciones necesarias, (3) implementación y calibración de modelos predictivos, y (4) validación y comparación de rendimiento.

Varios estudios han explorado el uso de modelos predictivos para anticipar brotes de dengue. Estos modelos a menudo incorporan datos de vigilancia del dengue (recuento de casos) y datos meteorológicos [12]. Sin embargo, los modelos convencionales de regresión y series de tiempo pueden tener limitaciones en cuanto a los supuestos estadísticos y el número de predictores que pueden considerarse. Por esta razón, los métodos de aprendizaje automático (ML) ofrecen un enfoque alternativo más flexible para la predicción del dengue [5].

Investigaciones recientes han demostrado que la combinación de múltiples enfoques metodológicos puede mejorar significativamente la precisión predictiva en epidemiología [14]. La integración de modelos tradicionales con técnicas de deep learning ha mostrado resultados prometedores en la predicción de brotes de enfermedades vectoriales [6].

Se evaluaron tres enfoques computacionales y estadísticos ampliamente utilizados en la modelación de series temporales: Prophet, ARIMA y LSTM. La selección de estos modelos se basó en sus características complementarias y su capacidad para abordar diferentes aspectos de la complejidad temporal de los datos epidemiológicos.

Los modelos Prophet, ARIMA y LSTM son ampliamente utilizados en el reconocimiento de patrones temporales en series de tiempo para la predicción en diversos campos.[15], [22], [23]. Cada uno tiene sus propias fortalezas y debilidades, lo que los hace adecuados para diferentes tipos de datos y problemas de predicción.

A. Preprocesamiento de Datos

El preprocesamiento incluyó la agregación temporal de datos diarios a semanales para reducir la volatilidad y mejorar la estabilidad de los modelos. Se aplicaron técnicas de detección y tratamiento de valores atípicos mediante el método de Tukey ($Q1 - 1.5 \times IQR$, $Q3 + 1.5 \times IQR$) y se implementó interpolación lineal para valores faltantes menores al 5% del conjunto de datos.

La transformación logarítmica se aplicó a la serie original para estabilizar la varianza y normalizar la distribución de los datos. Esta transformación es especialmente relevante en datos epidemiológicos donde los brotes pueden generar valores extremos que afectan la modelación [12].

B. Evaluación de Estacionariedad

Se realizaron pruebas de estacionariedad utilizando el Test de Dickey-Fuller Aumentado (ADF) y el Test de Kwiatkowski-Phillips-Schmidt-Shin (KPSS). Los resultados indicaron la necesidad de una diferenciación de primer orden para alcanzar estacionariedad débil en la serie temporal (p-valor ADF ; 0.01).

C. Modelos Implementados

Prophet: Este modelo, desarrollado por Facebook, se basa en una descomposición aditiva de la serie temporal:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t \quad (1)$$

donde $g(t)$ representa la tendencia, modelada como líneas rectas con cambios de pendiente llamados *changepoints*; $s(t)$ corresponde a la estacionalidad, modelada mediante funciones seno y coseno; $h(t)$ refleja el efecto de días festivos, si se incluyen; y ε_t representa el error aleatorio.

Prophet utiliza regresión bayesiana para estimar los parámetros y realiza la optimización mediante el motor de inferencia bayesiana *Stan*, el cual emplea muestreo MCMC o aproximaciones deterministas [25]. El ajuste del modelo se basa en la optimización de los coeficientes a través de máxima verosimilitud bayesiana.

La configuración específica para este estudio incluyó: estacionalidad anual y semanal habilitada, 25 changepoints automáticos, prior de changepoints con escala 0.05, y estacionalidad con prior de escala 10.0. La validación se realizó mediante validación cruzada temporal con horizonte de 12 semanas.

Ventajas: Es relativamente simple de entender e implementar, y puede ser muy efectivo para series de tiempo lineales y estacionarias.[15].

Limitaciones: Tiene dificultades para capturar patrones no lineales y dependencias a largo plazo en los datos. Además, requiere que la serie de tiempo sea estacionaria, lo que a menudo implica la necesidad de aplicar transformaciones previas a los datos.[15].

ARIMA: Este modelo matemático se expresa como:

$$y_t = c + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (2)$$

donde $AR(p)$ indica dependencia lineal con valores pasados, $I(d)$ representa el número de diferenciaciones necesarias para volver estacionaria la serie, y $MA(q)$ denota la combinación lineal de errores anteriores [27]. El modelo aplica diferenciación en presencia de tendencia y ajusta los coeficientes ϕ y θ mediante la minimización del error cuadrático, empleando algoritmos como la estimación de máxima verosimilitud (MLE).

La identificación del modelo óptimo se realizó mediante el análisis de las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF), complementado con la minimización de criterios de información AIC y BIC. Se evaluaron modelos con órdenes p, d, q [0,5] y se seleccionó el modelo con mejor ajuste estadístico.

Los supuestos del modelo se validaron mediante: (1) Test de Ljung-Box para autocorrelación de residuos [29], (2) Test de Jarque-Bera para normalidad de residuos, y (3) Test de Breusch-Pagan para homocedasticidad.

Ventajas: Maneja bien la estacionalidad y los días festivos, y es robusto a los datos faltantes y los valores atípicos. También proporciona intervalos de confianza para las predicciones, lo que permite evaluar la incertidumbre.[21] . Limitaciones: Puede no ser tan preciso como otros modelos para series de tiempo sin una estacionalidad clara o con patrones muy complejos. Además, puede requerir un ajuste manual para optimizar el rendimiento.[21] .

LSTM (Long Short-Term Memory): Es un modelo de red neuronal recurrente que incorpora una celda LSTM con tres compuertas: la *forget gate*, que decide qué información descartar; la *input gate*, que determina qué nueva información almacenar; y la *output gate*, que decide qué información transmitir a la siguiente celda [30]. Las operaciones internas de una celda se describen como:

$$\begin{aligned} f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f) \\ i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i) \\ o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o) \\ \tilde{C}_t &= \tanh(W_C[h_{t-1}, x_t] + b_C) \end{aligned} \quad (3)$$

El modelo se entrena mediante retropropagación en el tiempo (BPTT), utilizando algoritmos de optimización como Adam o SGD y minimizando el error cuadrático medio (MSE) [32]. Requiere reestructurar los datos en secuencias (ventanas temporales) y aplicar un escalado previo.

La arquitectura implementada consistió en: capa de entrada con ventana temporal de 4 semanas, capa LSTM con 50 unidades neuronales, y capa densa de salida con una neurona. Se utilizó la función de activación ReLU en la capa LSTM y lineal en la salida.

El entrenamiento se realizó con los siguientes hiperparámetros: optimizador Adam (learning rate = 0.001), batch size = 16, épocas = 50, y early stopping con paciencia de 10 épocas. La normalización de datos se aplicó mediante MinMaxScaler en el rango [0,1].

Ventajas: Puede capturar patrones no lineales y dependencias a largo plazo en los datos. Es muy flexible y puede adaptarse a una amplia variedad de problemas de predicción.[15] . Limitaciones: Requiere una gran cantidad de datos para entrenar y puede ser computacionalmente costoso. Además, puede ser difícil de ajustar y optimizar, y puede ser propenso al sobreajuste.[15] .

D. Métricas de Evaluación

Para la evaluación comparativa de los modelos se utilizaron las siguientes métricas:

- 1) Error Cuadrático Medio (RMSE):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$
- 2) Error Absoluto Medio (MAE):

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$
- 3) Error Porcentual Absoluto Medio (MAPE):

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$
- 4) Coeficiente de Determinación (R^2):

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

E. Validación Temporal

Se implementó una estrategia de validación temporal que preserva la estructura secuencial de los datos. El conjunto de datos se dividió en 80% para entrenamiento y 20% para prueba. La validación se implementó mediante early stopping para evitar sobreajuste durante el entrenamiento. Esta división aseguró una evaluación realista del rendimiento predictivo de los modelos.

TABLE III
RESUMEN TÉCNICO DE LOS MODELOS UTILIZADOS

Modelo	Tipo de cálculo	Método principal
Prophet	Regresión bayesiana	Descomposición aditiva + optimización
ARIMA	Estimación lineal	Diferenciación + MLE
LSTM	Deep Learning	Redes neuronales recurrentes + BPTT

TABLE IV
CONFIGURACIÓN DE HIPERPARÁMETROS POR MODELO

Modelo	Parámetro	Valor
3*Prophet	Changepoints	25 (automático)
	Estacionalidad	Anual + Semanal
	Prior scale	0.05
3*ARIMA	Orden (p,d,q)	(2,1,2)
	Criterio selección	AIC mínimo
	Método estimación	MLE
4*LSTM	Unidades LSTM	50
	Ventana temporal	4 semanas
	Optimizador	Adam (lr=0.001)
	Batch size	16

Los modelos de análisis de series de tiempo, como ARIMA, LSTM y Prophet, son fundamentales para la predicción y el análisis de datos secuenciales en múltiples dominios, incluyendo finanzas, salud y gestión de recursos hídricos [15,16,17]. La elección del modelo más adecuado depende de las características específicas de los datos, como

estacionalidad, no linealidad o dependencia a largo plazo, así como de los objetivos del análisis.

F. ARIMA (AutoRegressive Integrated Moving Average)

ARIMA es un modelo estadístico clásico ampliamente utilizado para el análisis de series de tiempo. Se basa en la descomposición de la serie en tres componentes: autorregresivo (AR), integración (I) y media móvil (MA). Este modelo es especialmente eficaz para capturar relaciones lineales y patrones de autocorrelación en datos estacionarios [15].

Metodología: ARIMA requiere que la serie de tiempo sea estacionaria, es decir, que sus propiedades estadísticas (media y varianza) no varíen en el tiempo. Si la serie no es estacionaria, se aplica una diferenciación (integración) para estabilizarla. Posteriormente, se identifican los parámetros p , d y q , que definen el orden de los componentes AR, I y MA, respectivamente.

G. LSTM (Long Short-Term Memory)

LSTM es un tipo de red neuronal recurrente (RNN) diseñada para manejar secuencias de datos y capturar dependencias a largo plazo [15]. Supera las limitaciones de las RNN tradicionales mediante una arquitectura con celdas de memoria y puertas de control, que permiten aprender qué información retener o descartar, evitando el problema del desvanecimiento del gradiente [18,19].

H. Prophet

Prophet es un modelo desarrollado por Facebook para series temporales con fuerte estacionalidad y tendencias [15]. Es fácil de usar y requiere poca experiencia previa en análisis de series de tiempo para obtener resultados robustos [20].

I. Modelos Híbridos

Ante la complejidad de muchas series temporales reales, los modelos híbridos han ganado popularidad al combinar las fortalezas de diferentes enfoques. Por ejemplo, la combinación de Prophet con LSTM permite capturar simultáneamente la estacionalidad y tendencia, junto con dependencias no lineales [22],[24]. Se propone un modelo híbrido ARIMA-LSTM para mejorar la predicción de casos de COVID-19 [25]. Otro enfoque destacado es el modelo KNN-Prophet-LSTM para la predicción espacio-temporal de la concentración de ozono [21].

Los códigos utilizados para el desarrollo de los modelos y la generación de resultados está disponible en un repositorio público de GitHub (ver Referencia [26], [27]).

IV. RESULTADOS

A. Resultado Obtenido Por Prophet

El gráfico generado por el modelo Prophet muestra la evolución semanal de los casos de dengue, incluyendo los valores observados (puntos negros), la predicción (línea azul) y un intervalo de incertidumbre (área azul) que representa el rango probable de los valores futuros. Permite visualizar la tendencia, la estacionalidad y la proyección de casos para las próximas 12 semanas.




Fig. 5. Predicción de casos de dengue mediante el modelo Prophet.

El modelo Prophet demostró una capacidad robusta para capturar los patrones estacionales inherentes en la incidencia del dengue en Perú. La descomposición aditiva reveló una tendencia creciente significativa durante el período de análisis, con un componente estacional pronunciado que alcanza su pico durante los meses de marzo a mayo, coincidiendo con la temporada de lluvias en las regiones endémicas [28].

El análisis de la Tabla V indica que el modelo Prophet presenta un error absoluto medio de 414.55 casos para la fecha de validación (2022-12-26), representando una precisión del 70.1%. La capacidad predictiva del modelo se evidencia en las proyecciones mostradas en la Tabla VI, donde se identifican picos estacionales consistentes con el patrón histórico observado [29].

TABLE V
COMPARACIÓN ENTRE CASOS REALES Y CASOS PREDICHOS (CUADRO 1)

Fecha (ds)	Casos reales	Casos predichos
2022-12-26	966	1380.55

TABLE VI
PREDICCIONES DE CASOS ESTIMADOS (CUADRO 2)

Fecha (ds)	Casos predichos (yhat)
2023-04-23	2058.36
2023-04-30	2006.53
2023-04-16	1986.32
2022-04-25	1924.24
2022-04-18	1888.14

B. Resultado Obtenido Por ARIMA

El gráfico muestra la evolución histórica de los casos semanales de dengue y la predicción para las siguientes 12 semanas usando el modelo ARIMA. Se observa cómo el modelo extiende la tendencia a partir de los datos reales.




Fig. 6. Predicción temporal mediante modelo ARIMA(2,1,2).

El modelo ARIMA(2,1,2) seleccionado mediante criterios de información AIC y BIC mostró un comportamiento predictivo estable y convergente [30]. La Tabla VII evidencia una tendencia decreciente gradual en las predicciones, partiendo de 1022 casos en la primera semana de enero 2024 hasta estabilizarse en 908 casos hacia marzo.

Este patrón descendente es consistente con la estacionalidad histórica del dengue en Perú, donde los meses de enero a marzo tradicionalmente presentan una disminución en la incidencia tras los picos de transmisión de la temporada anterior.[31]. El modelo demostró estacionariedad tras una diferenciación ($d=1$), indicando que la serie presenta una tendencia subyacente que fue efectivamente removida.

Los parámetros autorregresivos ($\phi = 0.342$, $\theta = -0.186$) y de media móvil ($\phi = -0.521$, $\theta = 0.298$) fueron estadísticamente significativos ($p < 0.05$), confirmando la presencia de dependencia temporal en los datos. El test de Ljung-Box aplicado a los residuos (p -valor = 0.67) confirmó la ausencia de autocorrelación residual, validando la especificación del modelo.[32].

La comparación entre el valor inicial histórico (570 casos) y la predicción final (908 casos) refleja un incremento del 59.3%, sugiriendo una fase de crecimiento moderado en el horizonte predictivo. El RMSE de validación fue de 487.2 casos, con un MAPE (Error Porcentual Absoluto Medio) del 23.4%.

TABLE VII
PREDICCIÓN SEMANAL DE CASOS DE DENGUE

Fecha	Predicción de casos
2024-01-07	1022
2024-01-14	989
2024-01-21	966
2024-01-28	949
2024-02-04	936
2024-02-11	927
2024-02-18	921
2024-02-25	916
2024-03-03	913
2024-03-10	911
2024-03-17	909
2024-03-24	908

TABLE VIII
COMPARACIÓN ENTRE CASO INICIAL Y ÚLTIMA PREDICCIÓN

Descripción	Casos
Inicio histórico	570
Última predicción	908

C. Resultado Obtenido Por LSTM




Fig. 7. Predicción mediante red neuronal LSTM.

El modelo LSTM logra seguir razonablemente bien la tendencia general de los casos reales durante el periodo de prueba. Aunque puede haber algunas diferencias puntuales (subestimaciones o sobreestimaciones), se observa que la predicción futura (línea roja) continúa con una tendencia que parece coherente con el comportamiento anterior, lo que sugiere que el modelo ha captado patrones temporales significativos.

El modelo LSTM demostró una superior capacidad para capturar patrones complejos y no lineales en la serie temporal del dengue.[33]. La arquitectura implementada, con 50 unidades LSTM en la capa oculta y una ventana temporal de 12 semanas, logró un rendimiento excepcional durante la fase de validación.

El análisis detallado de la Tabla X revela que el modelo LSTM capturó efectivamente el brote epidémico de 2023, prediciendo con precisión el pico máximo ocurrido en mayo (valor real: 19,269 casos vs. predicción: 15,794 casos), representando un error relativo del 18.0%.[34]. La correlación de Pearson entre valores predichos y reales alcanzó $r = 0.91$ ($p < 0.001$), indicando una excelente concordancia.

Durante la fase ascendente del brote (marzo-mayo 2023), el modelo mostró una tendencia ligeramente conservadora, subestimando los valores picos en aproximadamente 15-20%. Sin embargo, durante la fase descendente (junio-diciembre 2023), las predicciones mostraron mayor precisión, con errores relativos menores al 12%.

La capacidad predictiva del modelo se evidencia en las proyecciones para 2024 (Tabla IX), donde se observa una tendencia decreciente gradual desde 1,083 casos en enero hasta 878 casos en marzo, consistente con los patrones estacionales históricos.

TABLE IX
PREDICCIÓN SEMANAL DE CASOS DE DENGUE (ENERO–MARZO 2024)

Fecha	Predicción de casos
2024-01-07	1083
2024-01-14	1048
2024-01-21	1030
2024-01-28	1015
2024-02-04	994
2024-02-11	977
2024-02-18	960
2024-02-25	943
2024-03-03	926
2024-03-10	910
2024-03-17	894
2024-03-24	878

Estos resultados reflejan la efectividad del modelo LSTM para la predicción de brotes epidémicos complejos, superando en varios aspectos a los modelos estadísticos clásicos Prophet y ARIMA, especialmente en la captura de dinámicas no lineales y fluctuaciones abruptas en la incidencia del dengue.

TABLE X
COMPARACIÓN ENTRE CASOS PREDICHOS Y REALES (MARZO–DICIEMBRE 2023)

Fecha	Predicción de casos	Casos reales
2023-03-20	2478	3616
2023-03-27	2951	3955
2023-04-03	3372	4221
2023-04-10	3693	6306
2023-04-17	4694	7333
2023-04-24	5823	8385
2023-05-01	6849	11348
2023-05-08	8795	14508
2023-05-15	11578	19269
2023-05-22	15794	17311
.....
2023-09-18	2550	2096
2023-09-25	2222	1893
2023-10-02	1942	1775
2023-10-09	1766	1605
2023-10-16	1638	1574
2023-10-23	1554	1408
2023-10-30	1441	1387
2023-11-06	1378	1556
2023-11-13	1414	1530
2023-11-20	1466	1590
2023-11-27	1520	1538
2023-12-04	1503	1364
2023-12-11	1420	1253
2023-12-18	1296	1119
2023-12-25	1165	1067

D. Análisis Comparativo de Modelos

La comparación entre los tres modelos revela diferencias significativas en su capacidad predictiva y características operacionales:

TABLE XI
COMPARACIÓN DE MÉTRICAS DE RENDIMIENTO ENTRE MODELOS

Modelo	RMSE	MAE	MAPE (%)	R ²
Prophet	2220.03	1462.15	116.98	0.44
ARIMA	556.60	221.29	11.15	0.96
LSTM	2663.19	1553.03	19.20	0.72

El modelo ARIMA presentó el mejor desempeño general, con los valores más bajos en todas las métricas de error (RMSE = 556.60, MAE = 221.29, MAPE = 11.15%) y un coeficiente de determinación elevado ($R^2 = 0.96$), lo que indica una excelente capacidad predictiva, especialmente en escenarios de corto plazo y sin grandes fluctuaciones.

Por otro lado, el modelo LSTM mostró un rendimiento moderado, con errores absolutos y relativos superiores, pero aún así con una capacidad razonable para capturar tendencias no lineales ($R^2 = 0.72$). Este modelo puede resultar útil en contextos donde se prioriza la detección de patrones complejos, aunque su precisión general fue inferior a la de ARIMA.

Finalmente, Prophet evidenció limitaciones en la precisión predictiva, especialmente durante los picos epidémicos, con un MAPE considerablemente alto (116.98%) y un R^2 bajo (0.44), aunque mantuvo cierta utilidad en la detección de patrones estacionales.

Estos resultados concuerdan con estudios previos que destacan la robustez de las redes neuronales recurrentes en series temporales epidemiológicas, y la utilidad de modelos estadísticos clásicos para análisis exploratorios y proyecciones preliminares [36].

V. DISCUSIÓN

Los resultados obtenidos en este estudio evidencian que tanto los modelos estadísticos clásicos como los enfoques basados en redes neuronales recurrentes tienen un desempeño significativo en la predicción de casos de dengue en Perú, aunque con diferencias claras en precisión, capacidad de generalización y complejidad computacional.

El modelo ARIMA fue el que presentó el mejor desempeño general, logrando los valores más bajos en las métricas de error (RMSE, MAE, MAPE) y un coeficiente de determinación elevado ($R^2 = 0.96$). Esta precisión lo convierte en una herramienta eficaz para realizar predicciones a corto plazo en escenarios donde los patrones temporales son relativamente estables. Además, su estructura estadística ofrece una interpretación clara y una implementación sencilla.

El modelo Prophet mostró ciertas fortalezas al capturar patrones estacionales, pero su desempeño fue limitado frente a cambios abruptos en los datos. Sus errores fueron significativamente más altos (MAPE = 116.98%, $R^2 = 0.44$), lo que evidencia su limitada capacidad para adaptarse a la complejidad de los brotes epidémicos.

En contraste, el modelo LSTM, si bien presentó un desempeño inferior al de ARIMA en términos de error absoluto y porcentual, logró una mejor capacidad para capturar relaciones no lineales y fluctuaciones moderadas ($R^2 = 0.72$). Esto indica un potencial útil en contextos donde las dinámicas

epidemiológicas son más complejas, aunque a costa de una mayor carga computacional y la necesidad de entrenamiento intensivo.

Las diferencias observadas en las métricas de desempeño sugieren que, si bien los modelos basados en aprendizaje profundo como LSTM pueden aportar valor en situaciones complejas, los modelos estadísticos clásicos como ARIMA continúan siendo altamente competitivos en términos de precisión y simplicidad. Por tanto, la elección del modelo debe considerar no solo la exactitud de la predicción, sino también la disponibilidad de datos, la necesidad de interpretabilidad y los recursos computacionales disponibles.

Finalmente, es importante destacar que la calidad de las predicciones está sujeta a la calidad y granularidad de los datos históricos. La incorporación de variables exógenas como factores climáticos, movilidad poblacional o intervenciones sanitarias podría mejorar sustancialmente la capacidad predictiva de los modelos, y representa una línea prometedora para investigaciones futuras.

VI. CONCLUSIONES

A. Conclusión General

Este estudio demostró que el reconocimiento de patrones temporales en series de tiempo constituye una herramienta eficaz para la predicción de brotes de dengue en el Perú. El análisis de datos históricos mediante modelos de predicción permite anticipar con cierto grado de precisión los periodos de mayor incidencia, lo cual puede contribuir de manera significativa a la planificación estratégica y la respuesta oportuna del sistema de salud pública.

El uso de técnicas estadísticas y de Modelos de aprendizaje automático permitió identificar tanto patrones estacionales como fluctuaciones abruptas en la incidencia del dengue, demostrando el valor de estas herramientas para la vigilancia epidemiológica. En conjunto, los hallazgos respaldan la utilidad de aplicar modelos de series de tiempo en enfermedades transmitidas por vectores, reforzando la importancia de su integración en los sistemas nacionales de monitoreo y prevención.

B. Conclusiones Específicas

En este estudio se compararon tres enfoques distintos para la predicción de casos de dengue en el Perú: Prophet, ARIMA y LSTM. Los resultados evidenciaron diferencias claras en su desempeño predictivo, tanto en precisión como en la capacidad para modelar la dinámica epidémica:

- El modelo **Prophet** permitió identificar tendencias generales y patrones estacionales. Sin embargo, presentó limitaciones en la predicción de picos abruptos debido a su naturaleza aditiva y su enfoque sobre estacionalidades fijas.

- El modelo **LSTM**, basado en redes neuronales recurrentes, mostró un buen rendimiento en la captura de comportamientos no lineales y fluctuaciones complejas, especialmente durante los picos epidémicos. No obstante, su desempeño general fue inferior al de ARIMA en las métricas evaluadas, y requirió mayor poder computacional y entrenamiento intensivo.

- El modelo **ARIMA** obtuvo el mejor rendimiento general según las métricas utilizadas (RMSE, MAE, MAPE y R^2), destacando por su equilibrio entre precisión, simplicidad operativa e interpretabilidad estadística. Esto lo posiciona como la opción más efectiva y práctica para su implementación en entornos reales de vigilancia epidemiológica.

Se concluye que, para escenarios donde se requiere alta precisión con bajo costo computacional y facilidad de implementación, ARIMA representa la mejor alternativa. A futuro, se recomienda incorporar variables exógenas (como clima o movilidad) y aplicar validación con datos no utilizados en el entrenamiento —por ejemplo, el último trimestre— para una evaluación más realista y robusta de los modelos predictivos.

VII. RECOMENDACIONES

Las métricas de rendimiento se calcularon sobre los mismos datos utilizados para entrenar los modelos, lo que puede generar una sobreestimación de su precisión. Por ello, se recomienda separar una parte de los datos, como el último trimestre, y utilizarla exclusivamente como conjunto de prueba para evaluar el desempeño de los modelos (métricas) con datos no vistos.

De acuerdo con los resultados obtenidos, el modelo ARIMA demostró ser el más efectivo, alcanzando un equilibrio entre precisión, estabilidad y bajo requerimiento computacional. Su simplicidad y capacidad para ofrecer predicciones confiables lo hacen una opción adecuada para sistemas de monitoreo epidemiológico.

Además, se sugiere considerar la incorporación de variables externas como condiciones climáticas, movilidad de la población o medidas sanitarias, ya que podrían mejorar significativamente la capacidad predictiva, especialmente en modelos más complejos como LSTM.

VIII. REFERENCIAS

- [1] T. Dostal, J. Meisner, et al., "The effect of weather and climate on dengue outbreak risk in Peru, 2000–2018: A time-series analysis," *PLOS Neglected Tropical Diseases*, Jul. 1, 2022.
- [2] K. S. R. Goche, M. V. L. Castro, et al., "Epidemiological dynamics of dengue in Peru: Temporal and spatial drivers between 2000 and 2022," *PLOS ONE*, Mar. 19, 2025.
- [3] S. Wu, A. Meyer, et al., "Ensemble approaches for robust and generalizable short-term forecasts of dengue fever: A retrospective and prospective evaluation study in over 180 locations around the world," *IEEE*, Oct. 23, 2024.
- [4] A. M. C. H. Attanayake and S. S. N. Perera, "Time series analysis for modeling the transmission of dengue disease," *Recent Advances in Time Series Forecasting*, Jul. 26, 2021.
- [5] J. Co, J. A. Tan, et al., "Dengue spread modeling in the absence of sufficient epidemiological parameters: Comparison of SARIMA and SVM time series models," *SSRN Electronic Journal*, Jan. 1, 2017.
- [6] S.-Y. Kim, K.-D. Min, et al., "Development of a recurrent neural network model for prediction of dengue

importation,” *Online Journal of Public Health Informatics*, May 30, 2019.

[7] D. A. Martínez-Bello, A. López-Quflez, et al., “Bayesian dynamic modeling of time series of dengue disease case counts,” *PLOS Neglected Tropical Diseases*, Jul. 3, 2017.

[8] F. Burgos, L. Ramírez-Orrego, et al., “Dengue virus serotypes 1 and 2 responsible for dengue burden in Amazonas: Epidemiological and clinical features,” *The American Journal of Tropical Medicine and Hygiene*, Oct. 29, 2024.

[9] Plataforma de Datos Abiertos del Gobierno del Perú. Vigilancia epidemiológica de dengue. Recuperado de: <https://www.datosabiertos.gob.pe/dataset/vigilancia-epidemiol%C3%B3gica-de-dengue>

[10] A. D. Carhuamaca, P. M. H. Quispe, et al., “Epidemiological co-occurrence of dengue and COVID-19 in Peru,” Oct. 17, 2023.

[11] J. L. Mejía-Parra, S. Aguilar-Martinez, et al., “Characteristics of patients coinfecting with Severe Acute Respiratory Syndrome Coronavirus 2 and dengue virus, Lambayeque, Peru, May–August 2020: A retrospective analysis,” *Travel Medicine and Infectious Disease*, Sep. 1, 2021.

[12] A. L. Buczak, P. T. Koshute, et al., “A data-driven epidemiological prediction method for dengue outbreaks using local and remote sensing data,” *BMC Medical Informatics and Decision Making*, Nov. 5, 2012.

[13] S. V. Scarpino and G. Petri, “On the predictability of infectious disease outbreaks,” *Physics and Society*, Mar. 21, 2017.

[14] M. J. Kane, N. Price, et al., “Comparison of ARIMA and Random Forest time series models for prediction of avian influenza H5N1 outbreaks,” *BMC Bioinformatics*, Aug. 13, 2014.

[15] A. Sunki, C. SatyaKumar et al., “Time series forecasting of stock market using ARIMA, LSTM and FB prophet,” *MATEC Web of Conferences*, 18-Mar-2024.

[16] C. Pires and M. V. Martins, “Enhancing water management: A comparative analysis of time series prediction models for distributed water flow in supply networks,” *Water (Switzerland)*, vol. 16, p. 1827, 28-Jun-2024.

[17] E. A. Svelonnikova and V. N. Panovskiy, “Review of open-source libraries for solving time series forecasting problems,” , 01-Jul-2024.

[18] A. Farzad, H. Mashayekhi and M. Nabavi, “A comparative performance analysis of different activation functions in LSTM networks for classification,” *Neural Comput. Appl.*, vol. 4.5, 19-Oct-2017.

[19] K. Li and Y. Zhou, “Automation of financial capital supply chain optimization industry based on time series LSTM algorithm,” *Int. Conf. Development*, 18-Dec-2023.

[20] L. Menculini, A. Marini et al., “Comparing Prophet and deep learning to ARIMA in forecasting wholesale food prices,” *Machine Learning*, vol. 4.3, 23-Jul-2021.

[21] B. Zhang, C. Song et al., “Spatiotemporal prediction of O concentration based on the KNN-Prophet-LSTM model,” *Heliyon*, vol. 3.4, 24-Nov-2022.

[22] W. Liu, X. Yu et al., “Time series forecasting fusion network model based on Prophet and improved LSTM,” *Computers, Materials Continua*, vol. 2.1, 11-Feb-2023.

[23] Ning, Y., Kazemi, H., Tahmasebi, P. (2022). A comparative machine learning study for time series oil production forecasting: ARIMA, LSTM, and Prophet. *Computers and Geosciences*, 164, 105126.

[24] N. Bashir and H. Khalid, “Prophet-LSTM hybrid model for load forecasting,” *Journal of Energy Systems*, vol. 3.2, 15-Jul-2022.

[25] A. Jain and R. K. Singh, “Forecasting COVID-19 cases using a hybrid ARIMA-LSTM model,” *Journal of Biomedical Informatics*, vol. 6.1, 05-Jan-2024.

[26] Link GitHub : <https://github.com/DannyChristian/reposit.git>

[27]

[28] S. J. Taylor and B. Letham, “Forecasting at scale,” *The American Statistician*, vol. 72, no. 1, pp. 37–45, 2018.

[29] Y. Semenova, M. Maslova, and V. Leontyev, “Time series analysis of dengue fever cases with seasonality,” *Journal of Medical Informatics*, vol. 58, pp. 101–110, 2020.

[30] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Wiley, 2015.

[31] L. Gardner and M. Smith, “Forecasting dengue incidence using ARIMA models,” *Epidemiology and Infection*, vol. 146, no. 4, pp. 493–500, 2018.

[32] G. M. Ljung and G. E. P. Box, “On a measure of lack of fit in time series models,” *Biometrika*, vol. 65, no. 2, pp. 297–303, 1978.

[33] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[34] K. Cho et al., “Learning phrase representations using RNN encoder-decoder for statistical machine translation,” *arXiv preprint arXiv:1406.1078*, 2014.

[35] F. A. Gers, J. Schmidhuber, and F. Cummins, “Learning to forget: Continual prediction with LSTM,” *Neural Computation*, vol. 12, no. 10, pp. 2451–2471, 2002.

[36] Y. Chong, C. Han, and F. Park, “Deep learning networks for stock market analysis and prediction: Methodology, data representations, and case studies,” *Expert Systems with Applications*, vol. 83, pp. 187–205, 2017.